




Modelamiento y Programación GIS



Cesar Ivan Alvarez

cesarivanalvarezmendoza@gmail.com

A grayscale photograph of a person with a beard, seen from the side, sitting at a desk and typing on a keyboard. A large computer monitor is in front of them, displaying a complex GIS map with various colored regions and lines. The background is slightly blurred, showing other computer monitors and office equipment.

Unidad 2 – Modelamiento GIS

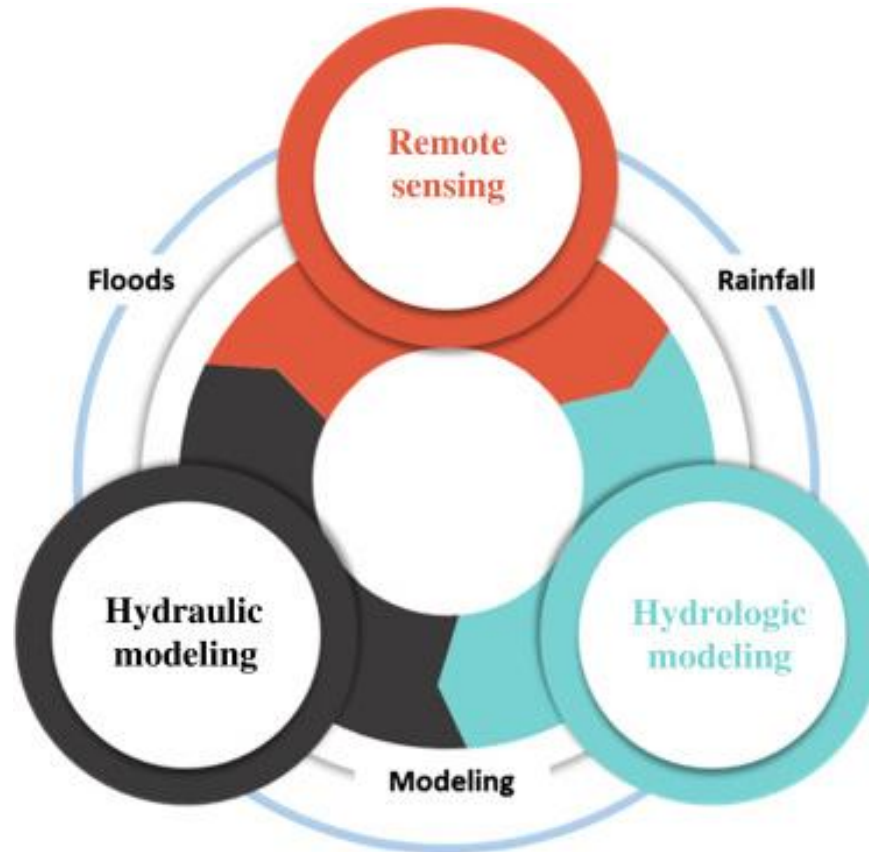
Qué es un modelo?



- Un algoritmo es el proceso basado en un lenguaje matemático para ser aplicado a un set de datos y lograr una función certera o propósito.
- Un modelo es la salida de un algoritmo que ha sido aplicado a un set de datos.
- Un modelo es un programa que ha sido entrenado con un set de datos para reconocer ciertos patrones o tomar ciertas decisiones, muchas veces sin la intervención humana, al referirnos a un modelo de AI.

(IBM, 2023)

Qué es un modelo espacial?



- El modelado espacial se refiere a la creación de representaciones simplificadas de la realidad que incorporan datos espaciales y otros datos relevantes para fines de análisis y toma de decisiones, particularmente en las ciencias de la Tierra y los planetarios.

(Elsevier, 2018)

La importancia de un modelo espacial



- Los modelos espaciales se centran en capturar las relaciones y los patrones espaciales dentro de una ubicación específica en un momento determinado. Estos modelos son ideales para situaciones en las que es esencial comprender la distribución espacial de características, como la densidad de población, el uso de la tierra o los hábitats de la vida silvestre.

Tipos de modelos geoespaciales

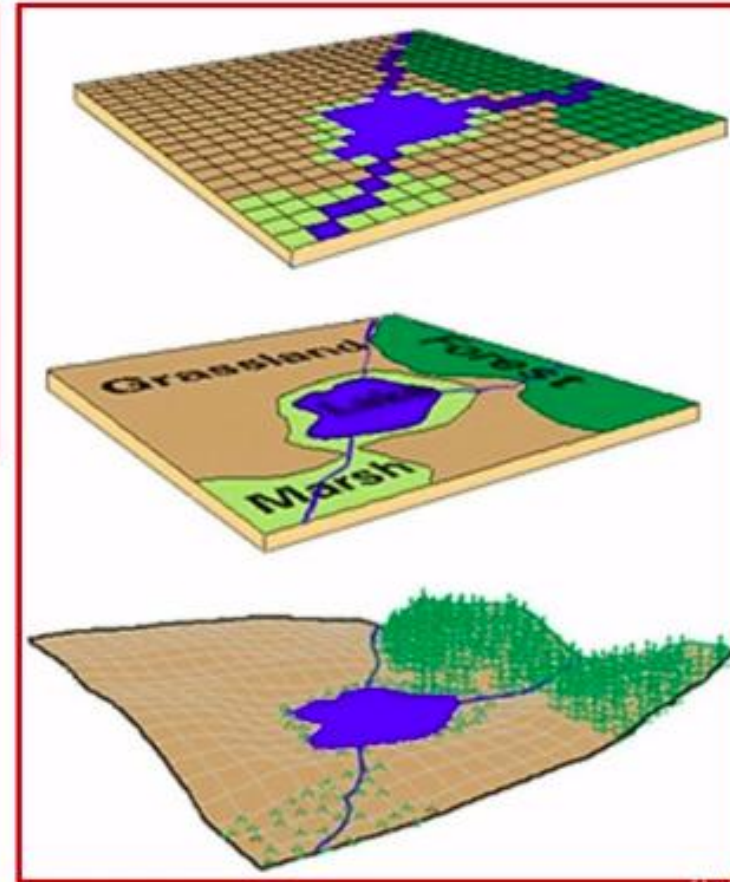


Category	Subcategory	Model Examples	Common Applications
Deterministic Models	Spatial Interpolation	IDW, Spline, TIN	Elevation surfaces, temperature, pollution
	Network Analysis	Shortest path, service area	Transportation, logistics, emergency services
Statistical Spatial Models	Global Spatial Regression	OLS, SAR, CAR	Econometrics, public health, crime patterns
	Local Spatial Regression	Geographically Weighted Regression (GWR)	Socioeconomic disparities, housing prices, environmental health
	Spatial Autocorrelation	Moran's I, Geary's C, Getis-Ord Gi*	Cluster detection, disease mapping, species distribution
Stochastic Models	Random Fields (Geostatistics)	Kriging, Gaussian Random Fields	Prediction of environmental variables with uncertainty
	Bayesian Spatial Models	Hierarchical Bayesian models, INLA, MCMC	Epidemiology, environmental modeling, poverty studies
Spatial Point Processes	Random or Clustered Point Patterns	Poisson, Cox, Thomas, Strauss	Event locations: crimes, trees, earthquakes, facilities
Simulation-Based Models	Monte Carlo Simulation	Spatial bootstrapping, random spatial patterns	Scenario evaluation, risk analysis
	Machine Learning models - Supervised Classification	Land-use change modeling	Land cover transitions, urban expansion
Agent-Based Models	Spatial Agent Behavior	NetLogo, UrbanSim	Urban growth, mobility, migration modeling
Spatio-Temporal Models	Spatio-Temporal Regression	STAR, GWR-T	Climate dynamics, disease spread, environmental change
	Spatio-Temporal Point Processes	Space-Time Poisson, STSS	Epidemic outbreaks, wildfire modeling
Raster	Spatial Analysis	Map Algebra	Risk maps, Multi-criteria analysis

Ejemplos de modelos espaciales

- Predicción de crecimiento urbano.
- Monitoreo de la deforestación.
- Evaluación de riesgo de inundaciones.
- Modelos de contaminantes.
- Modelos Topográficos (Interpolación).
- Modelos climatológicos.
- Modelos epidemiológicos.
- Modelos de riesgo a deslizamiento.
- Modelos agrícolas de predicción de biomasa, nutrientes, etc.
- Modelos de IA para detección de objetos.



Conceptos Fundamentales de Modelamiento Espacial – Tipos de Datos

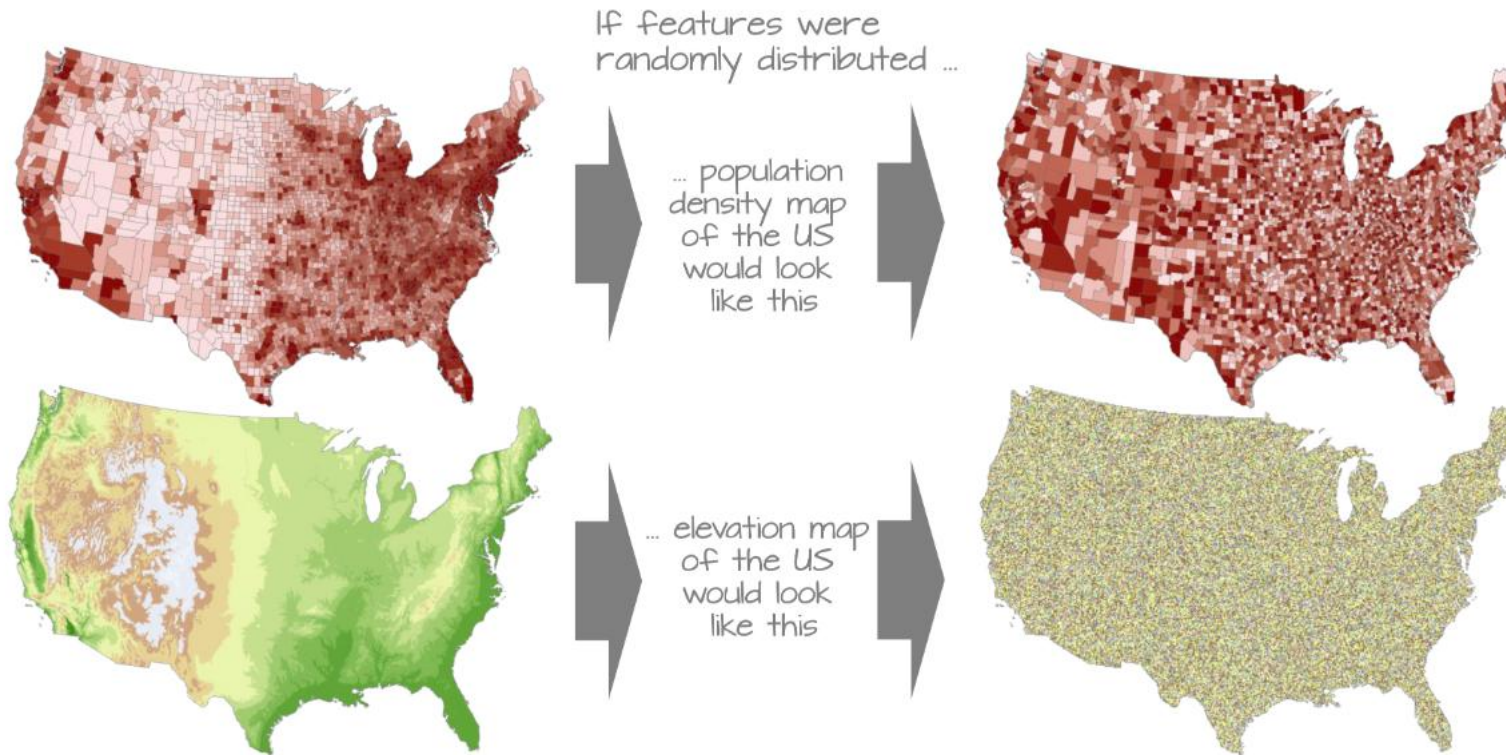


Tipo de Datos (Vector – Raster)

Conceptos Fundamentales de Modelamiento Espacial – Autocorrelación espacial

- La autocorrelación espacial se interpreta como un índice estadístico descriptivo que permite medir las formas y las maneras como se distribuyen los fenómenos analizados en el espacio geográfico (Goodchild 1986). La autocorrelación espacial mide el grado en el que una variable geográfica está correlacionada con ella misma en dos puntos o zonas diferentes del área de estudio.
- Es importante porque permite entender patrones espaciales, hacer predicciones y mejorar procesos de toma de decisiones.

Autocorrelación espacial

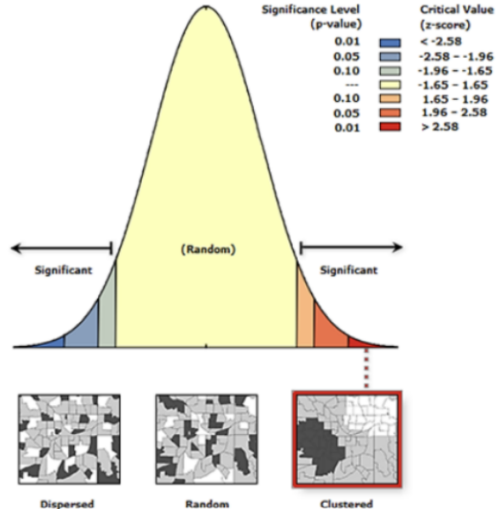


*"The first law of geography:
Everything is related to
everything else, but near things
are more related than distant
things."* Waldo R. Tobler ([Tobler 1970](#))


Análisis de Morán

Moran's I, Z-score

- Significant positive I – positive autocorrelation
- Significant negative I – negative autocorrelation



Moran's I



Moran's $I < E(I)$
indicates tend
to dispersion

Random
Moran's $I = E(I)$

Moran's $I > E(I)$
indicates tend
to clustering

- El análisis o coeficiente de Morán mide la relación entre valores de cada elemento de un dataset con el valor medio del mismo. Basado en esto, el coeficiente nos dirá si los datos son dispersos, aleatorios o agrupados (clusters).

Análisis de Morán – Coeficiente de Moran

Moran's I

Moran's I statistic is arguably the most commonly used indicator of global spatial autocorrelation. It was initially suggested by Moran (1948), and popularized through the classic work on spatial autocorrelation by Cliff and Ord (1973). In essence, it is a cross-product statistic between a variable and its spatial lag, with the variable expressed in deviations from its mean. For an observation at location i , this is expressed as $z_i = x_i - \bar{x}$, where \bar{x} is the mean of variable x .


Moran's I statistic is then:

$$I = \frac{\sum_i \sum_j w_{ij} z_i \cdot z_j / S_0}{\sum_i z_i^2 / n}$$


with w_{ij} as the elements of the spatial weights matrix, $S_0 = \sum_i \sum_j w_{ij}$ as the sum of all the weights, and n as the number of observations.

- $H_0: I = 0$
spatial pattern is random
- $H_1: I \neq 0$
spatial pattern is clustered/uniform

Moran's I Index = 0.47
Z Score = 45.92 standard deviations




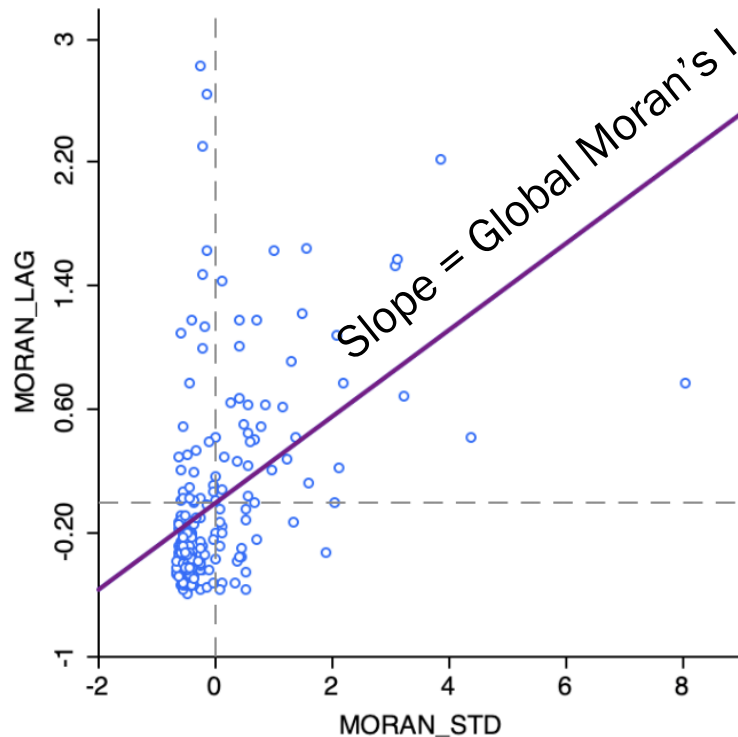
There is less than 1% likelihood that this clustered pattern could be the result of random chance.



Análisis de Morán - Moran Scatter PLOT

Local Indicators of Spatial Association (LISA) -
Spatial Association between neighbours

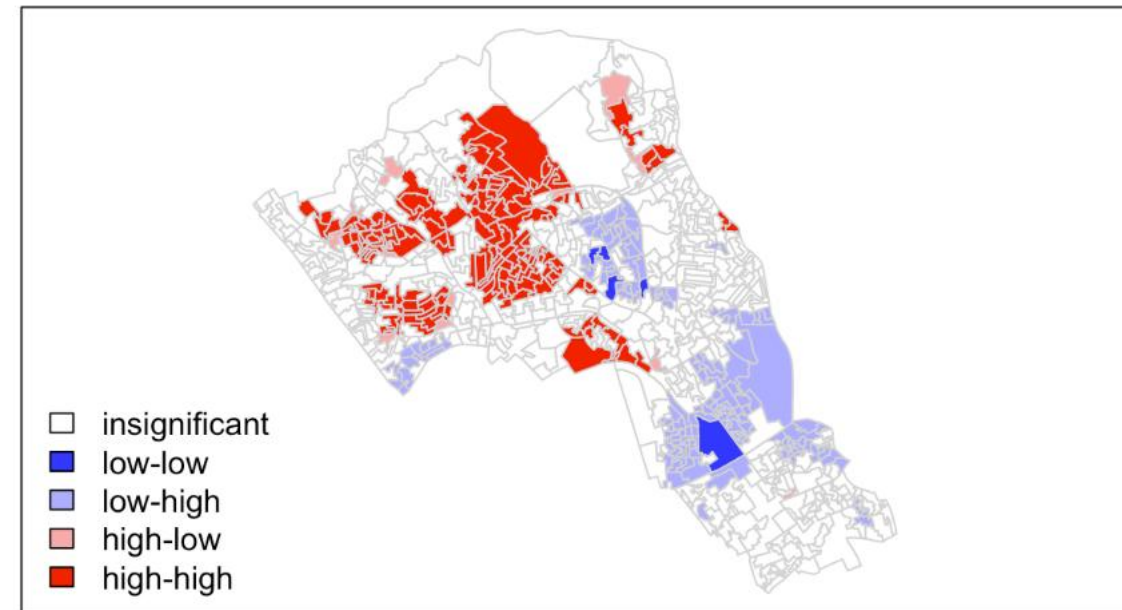
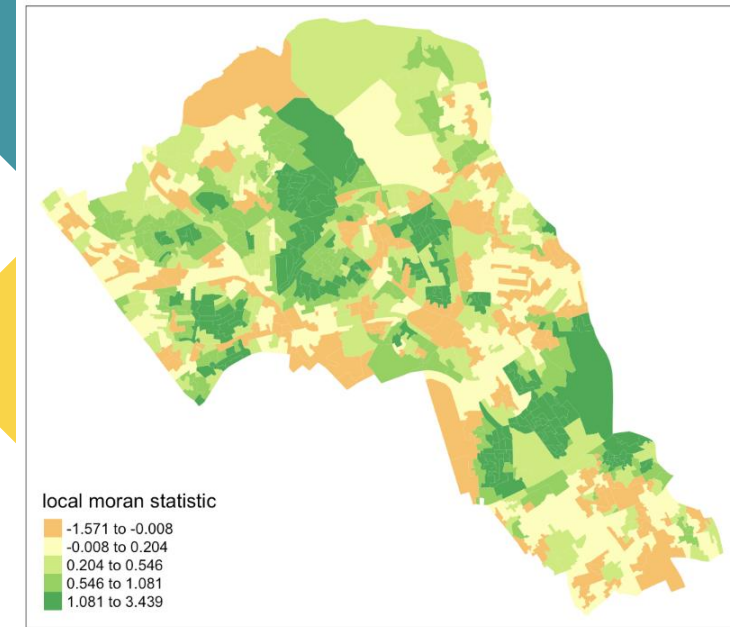
Local Moran's I statistic for
each spatial unit



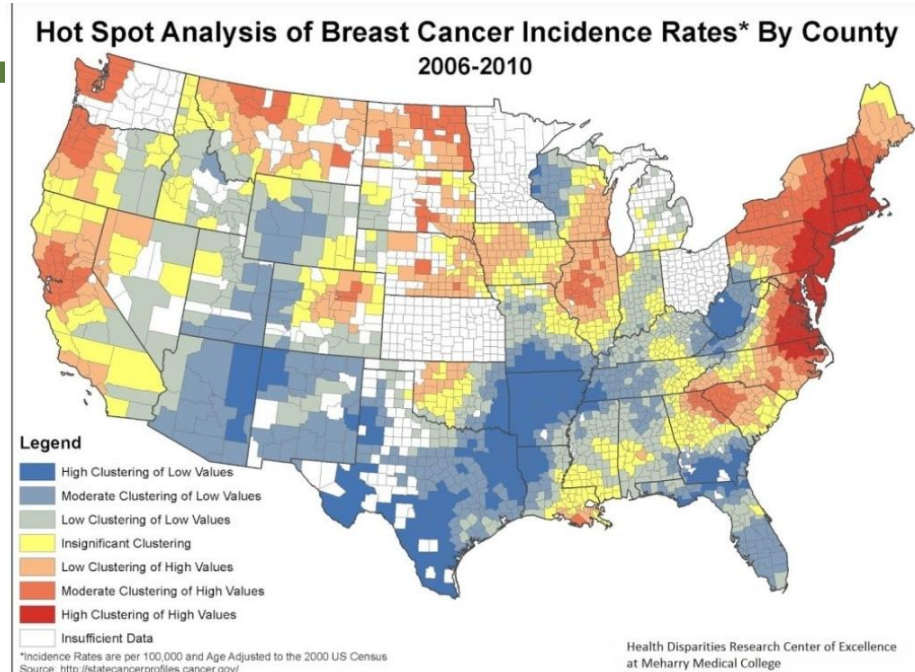
Análisis de Morán - LISA

<i>Asociación espacial</i>	<i>Global</i>	1) Índice de Moran	Reporte de autocorrelación espacial
	<i>Local</i>	2) LISA	Mapa de significancia Mapa de clústers

High-High (HH)	A high value surrounded by high values → hotspot
Low-Low (LL)	A low value surrounded by low values → cold spot
High-Low (HL)	A high value surrounded by low values → spatial outlier
Low-High (LH)	A low value surrounded by high values → spatial outlier
Not Significant	No statistically meaningful spatial relationship



Análisis de Puntos Calientes (Getis-Ord Gi)



The Getis-Ord local statistic is given as:

$$G_i^* = \frac{\sum_{j=1}^n w_{i,j} x_j - \bar{X} \sum_{j=1}^n w_{i,j}}{S \sqrt{\frac{n \sum_{j=1}^n w_{i,j}^2 - \left(\sum_{j=1}^n w_{i,j} \right)^2}{n-1}}} \quad (1)$$

where x_j is the attribute value for feature j , $w_{i,j}$ is the spatial weight between feature i and j , n is equal to the total number of features and:


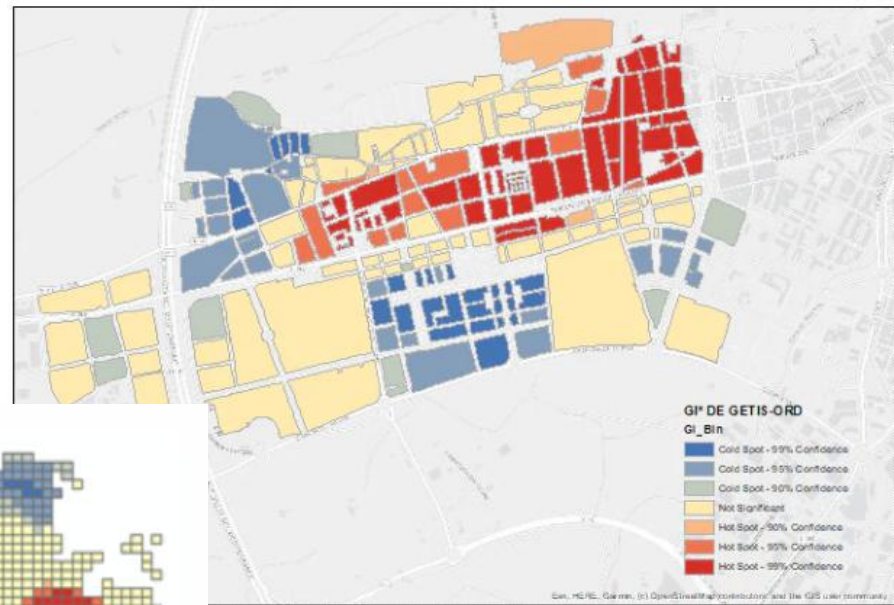

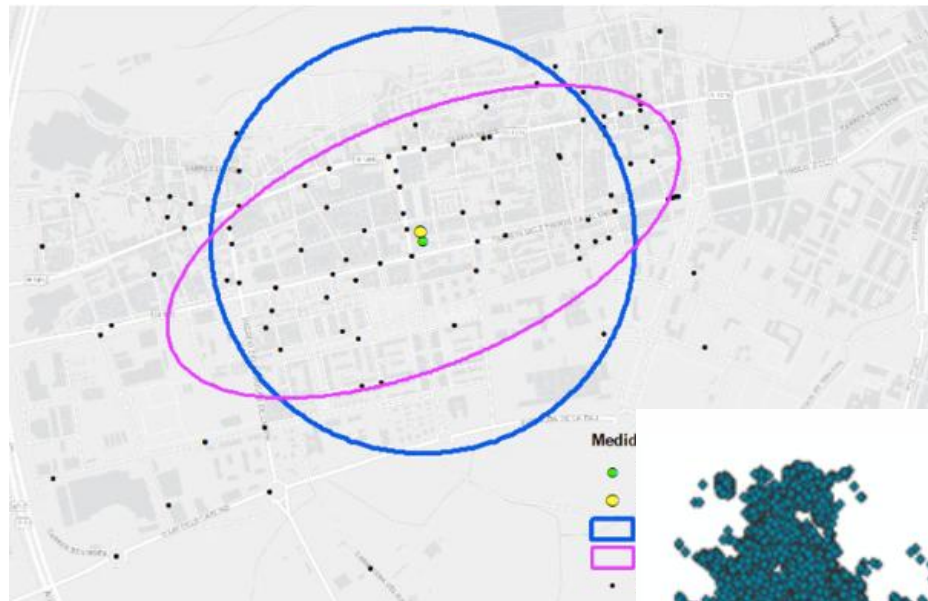
$$\bar{X} = \frac{\sum_{j=1}^n x_j}{n} \quad (2)$$

$$S = \sqrt{\frac{\sum_{j=1}^n x_j^2}{n} - (\bar{X})^2} \quad (3)$$

The G_i^* statistic is a z -score so no further calculations are required.

- La estadística G_i^* devuelta para cada entidad en el dataset es una puntuación z . Para las puntuaciones z positivas que son estadísticamente significativas, cuanto mayor sea la puntuación z , más intenso será el clustering de valores altos (puntos calientes). Para las puntuaciones z negativas que son estadísticamente significativas, cuanto más pequeña sea la puntuación z , más intenso será el clustering de valores bajos (punto frío).

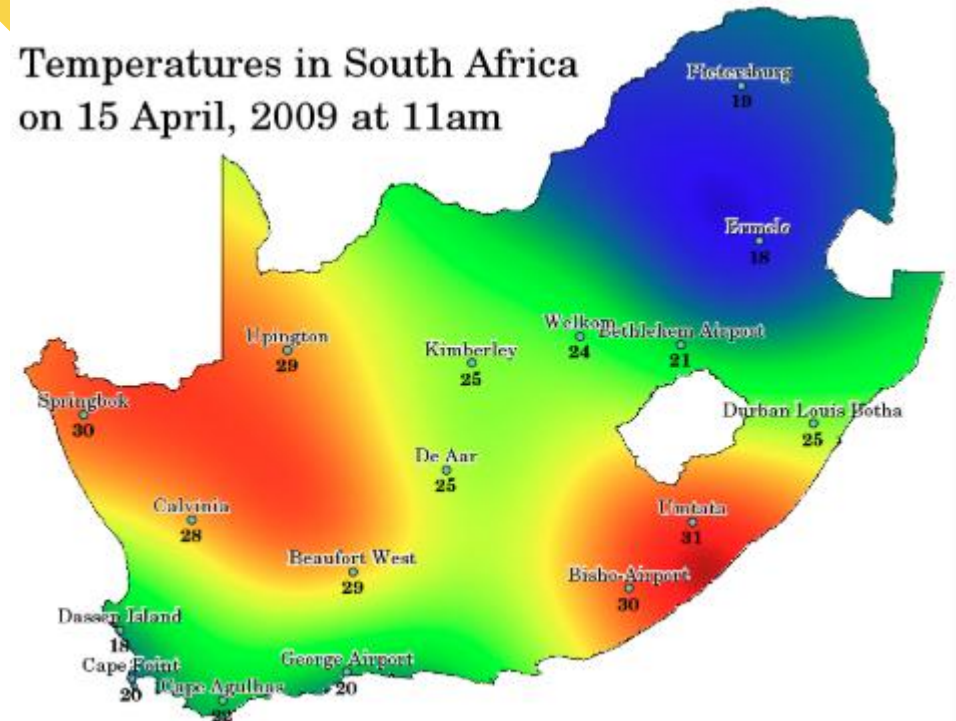
Análisis de Puntos Calientes (Getis-Ord Gi)




Interpolación Espacial

- La interpolación espacial es el proceso de utilizar puntos con valores conocidos para estimar valores en otros puntos desconocidos. Por ejemplo, para hacer un mapa de precipitaciones (precipitaciones) para su país, no encontrará suficientes estaciones meteorológicas distribuidas uniformemente para cubrir toda la región. La interpolación espacial puede estimar las temperaturas en lugares sin datos registrados mediante el uso de lecturas de temperatura conocidas en estaciones meteorológicas cercanas (QGIS, 2025). Este tipo de superficie interpolada a menudo se denomina superficie estadística.


Temperatures in South Africa
on 15 April, 2009 at 11am



Interpolación Espacial



Cálculo de la diferencia cuadrada entre las ubicaciones asociadas

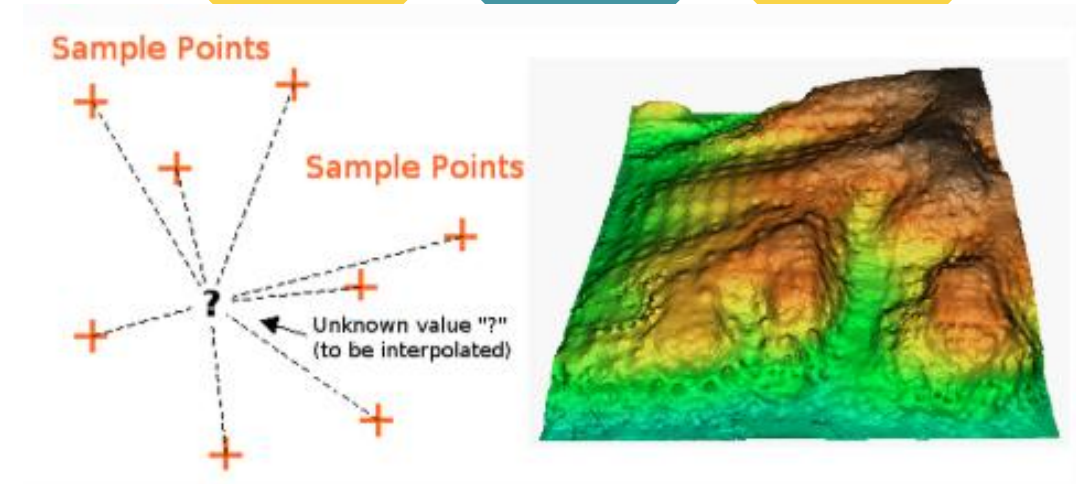


Vecindad de IDW del punto seleccionado


- Hay dos grupos principales de técnicas de interpolación: determinísticas y de estadísticas geográficas. Las técnicas de interpolación determinísticas crean superficies a partir de puntos medidos basándose en la extensión de la similitud (distancia inversa ponderada) o en el grado de suavizado (funciones de base radial). Las técnicas de interpolación de estadísticas geográficas (kriging) utilizan las propiedades estadísticas de los puntos medidos. Las técnicas de estadísticas geográficas cuantifican la autocorrelación espacial entre los puntos medidos y tienen en cuenta la configuración espacial de los puntos de muestra alrededor de la ubicación de predicción.

Inverse Distance Weighting (IDW)

- Esta interpolación se cataloga como determinista e interpola una superficie ráster a partir de puntos basándose principalmente en la inversa de la distancia elevada a una potencia matemática, en este método los puntos de muestreo se ponderan durante la interpolación, por lo cual, la influencia de un punto en relación con otros se reduce o disminuye a medida que aumenta la distancia entre ellos (ArcGIS, 2020).
- El parámetro Potencia permite controlar el peso o influencia de puntos conocidos en los valores interpolados basándose en la distancia desde el punto de salida; su valor suele ser 2, sin embargo, cuanto mayor sea el coeficiente de potencia, mayor será el peso de los puntos cercanos como se puede deducir de la ecuación que estima el valor z en una ubicación no muestreada j (ArcGIS, 2020).




Inverse Distance Weighting (IDW)




$$z_p = \frac{\sum_{i=1}^n \left(\frac{z_i}{d_i^p} \right)}{\sum_{i=1}^n \left(\frac{1}{d_i^p} \right)}$$

Para una potencia de 1, ese valor de celda es igual a:
 $((12/350) + (10/750) + (10/850)) / ((1/350) + (1/750) + (1/850)) = 11.1$



Para una potencia de 2, ese valor de celda es igual a:
 $= ((12/350^2) + (10/750^2) + (10/850^2)) / ((1/350^2) + (1/750^2) + (1/850^2)) = 11.4$



Taller 4

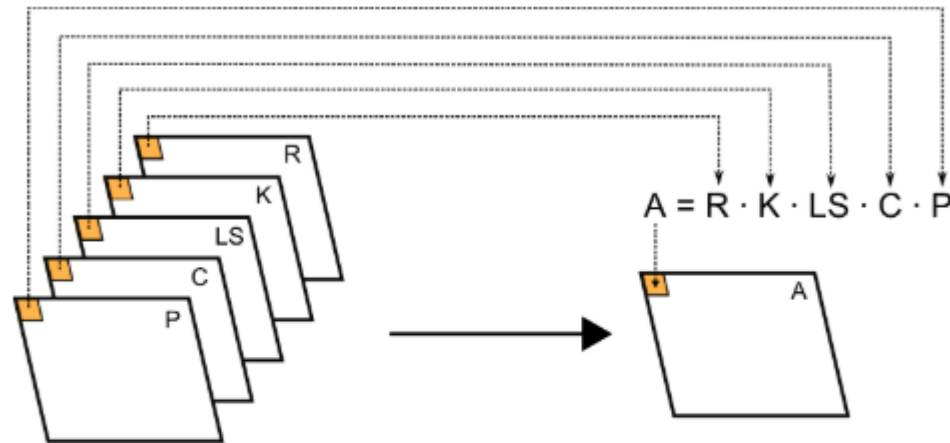
Con un Script de R:

Generar un mapa de interpolación para temperatura media de aire y precipitación acumulada IDW con los datos del INAMHI que se encuentran disponibles en la plataforma actual <https://inamhi.gob.ec/info/visor>. Utilizar los datos del ultimo día disponible para ambos parámetros.



Algebra de mapas

- Conjunto de técnicas y procedimientos que, operando sobre una o varias capas en formato ráster, nos permite obtener información derivada, generalmente en forma de nuevas capas de datos.



Puede extenderse una formula algebraica tal como la de la Ecuación Universal de Pérdidas de Suelo (USLE) a un conjunto de capas. Basta operar celda a celda con las capas que contienen las variables implicadas, para obtener una nueva capa resultante con el conjunto de valores calculados.


Tipos de Funciones en Algebra de mapas



Local	<ul style="list-style-type: none">• El valor en cada celda de la capa resultante es función únicamente de los valores en esa misma celda en las capas de partida.
Focal	<ul style="list-style-type: none">• El valor en cada celda de la capa resultante es función del valor en dicha celda y en las situadas en un entorno definido alrededor de la misma.
Zonal o regional	<ul style="list-style-type: none">• El valor en cada celda de la capa resultante es función del valor de todas las celdas conectadas a esta que presentan un mismo valor para una de las capas de entrada (pertenecen a la misma clase que esta).
Global	<ul style="list-style-type: none">• El valor resultante de la función es obtenido a partir de todas las celdas de la capa.

Tipos de Funciones en Algebra de mapas

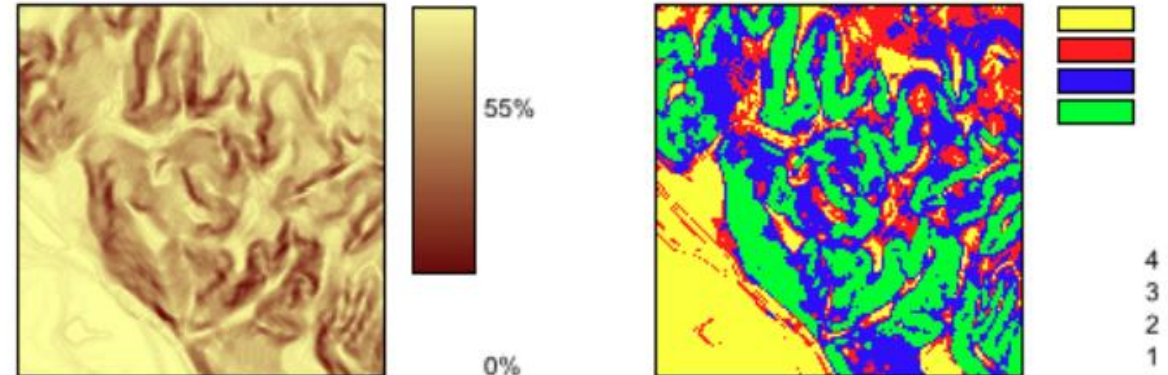
Funciones locales



Las funciones de análisis local analizan los valores de una celda concreta en una serie de capas para obtener el valor resultante. En rojo, celdas de partida analizadas. En verde, celda que recoge el resultado.

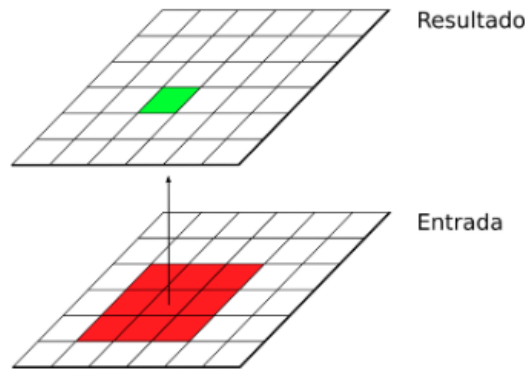
$$s' = \begin{cases} 1 & \text{si } s \leq 5 \\ 2 & \text{si } 5 < s \leq 10 \\ 3 & \text{si } 10 < s \leq 20 \\ 4 & \text{si } s > 20 \end{cases}$$

donde s' es la clase de pendiente, y s el valor de la pendiente en porcentaje.




Mediante una función local de reclasificación, podemos convertir una capa de valores continuos en una capa de clases con información discreta.

Algebra de mapas – Funcionales focales




Las funciones de análisis focal analizan los valores de una celda y las situadas en un entorno de esta para obtener el valor resultante. En rojo, celdas de partida analizadas. En verde, celda que recoge el resultado.



Resultados de un filtro de mediana sobre una imagen para distintos tamaños de ventana. a) 5×5 , b) 10×10 c) 20×20

Algebra de mapas – Funcionales zonales




Las funciones de análisis zonal analizan los valores de todas las celdas asociadas a una misma clase cada para obtener el valor resultante. En rojo, celdas de partida analizadas. En verde, celda que recoge el resultado.

a)	1	1	1	1	2	2
	1	1	1	1	2	2
	1	1	1	1	1	2
	1	2	1	1	1	1
	1	2	2	2	2	1
	2	2	2	2	2	1


b)	1	1	1	1	2	2
	1	1	1	1	2	2
	1	1	1	1	1	2
	1	2	1	1	1	1
	1	2	2	2	2	1
	2	2	2	2	2	1

Formas de definir las clases para el análisis zonal. En verde, celda de análisis. En rojo, celdas a considerar en su misma clase para ser empleadas en el cálculo. a) asignación por valor con contigüidad, b) asignación únicamente por valor.

Algebra de mapas – Funcionales globales

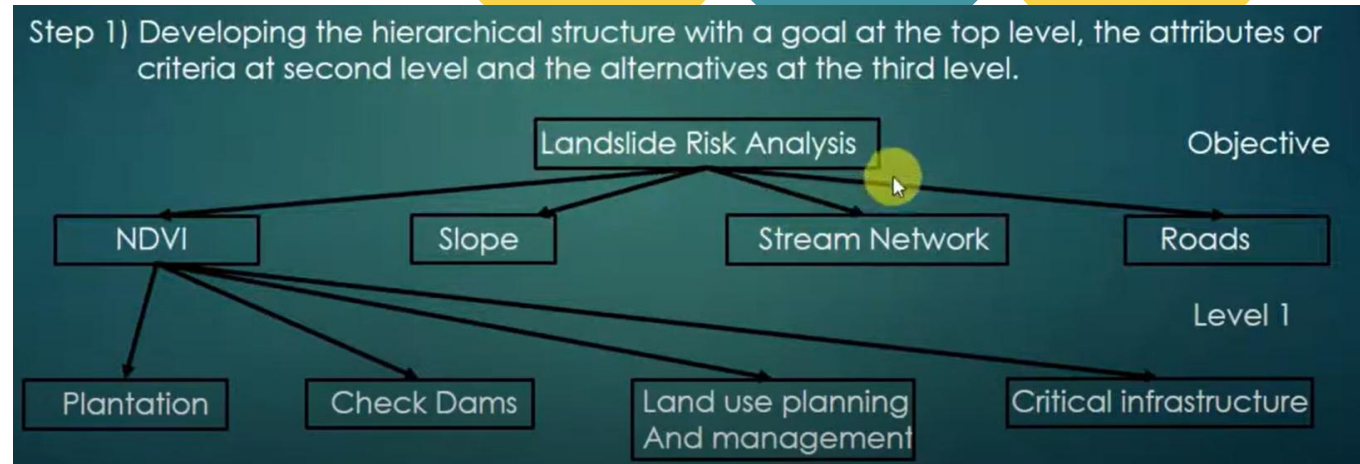
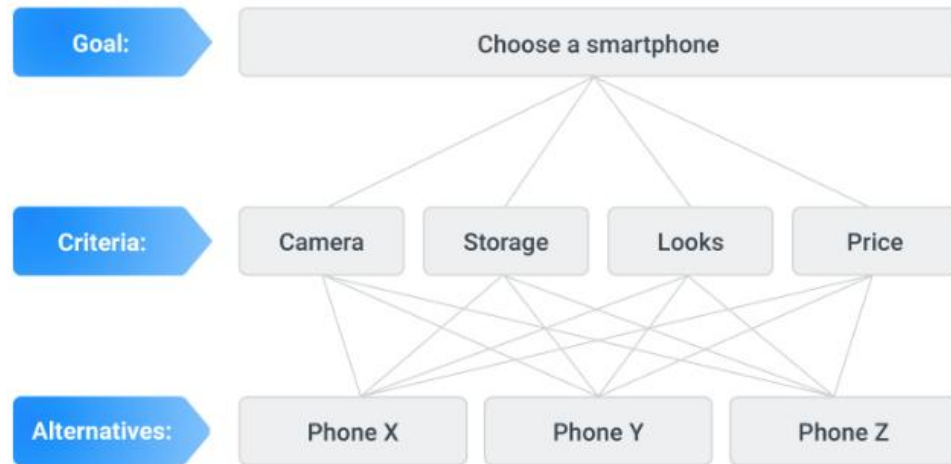


Las funciones de análisis global analizan el conjunto de valores de una capa para obtener un valor resultante, que puede ser tanto un objeto geográfico (capa ráster o vectorial) como un valor escalar sencillo, una tabla u otro tipo de resultado.



Dada una ruta y una capa, podemos obtener un perfil de valores a lo largo de la ruta mediante una función global.

Multicriterion Analytical Hierarchy Process (AHP)



El Proceso Analítico Jerárquico (AHP) es un método de análisis de decisiones de criterios múltiples (MCDA) que comienza descomponiendo las decisiones en una estructura jerárquica de un objetivo de toma de decisiones, criterios y alternativas (Saaty, 1977 and 1980).

Multicriterion Analytical Hierarchy Process (AHP)

Pair-wise Comparison Matrix

	NDVI	Slope	Stream Network	Roads
NDVI		$\frac{5x}{x} = 5$		
Slope	$\frac{x}{5x} = \frac{1}{5}$			
Stream Network				
Roads				

Row Element
Column Element

1	Equal Importance
3	Moderate Importance
5	Strong Importance
7	Very Strong Importance
9	Extreme Importance
2,4,6,8	Intermediate Values
1/3,1/5,1/7,1/9	Values for inverse comparison

How important is NDVI with respect to Slope?

NDVI is of **strong importance** than Slope

Slope-**x** value

NDVI- **5x** value

Multicriterion Analytical Hierarchy Process (AHP)

Pair-wise Comparison Matrix

Dividing each cell by sum of values of corresponding column

	NDVI	Slope	Stream Network	Roads
NDVI	$\frac{1}{1.59}$	$\frac{5}{8.33}$	$\frac{4}{5.83}$	$\frac{7}{14}$
Slope	$\frac{0.2}{1.59}$	$\frac{1}{8.33}$	$\frac{0.5}{5.83}$	$\frac{3}{14}$
Stream Network	$\frac{0.25}{1.59}$	$\frac{2}{8.33}$	$\frac{1}{5.83}$	$\frac{3}{14}$
Roads	$\frac{0.14}{1.59}$	$\frac{0.33}{8.33}$	$\frac{0.33}{5.83}$	$\frac{1}{14}$
Sum	1.59	8.33	5.83	14

Multicriterion Analytical Hierarchy Process (AHP)

Normalised Pair-wise Comparison Matrix

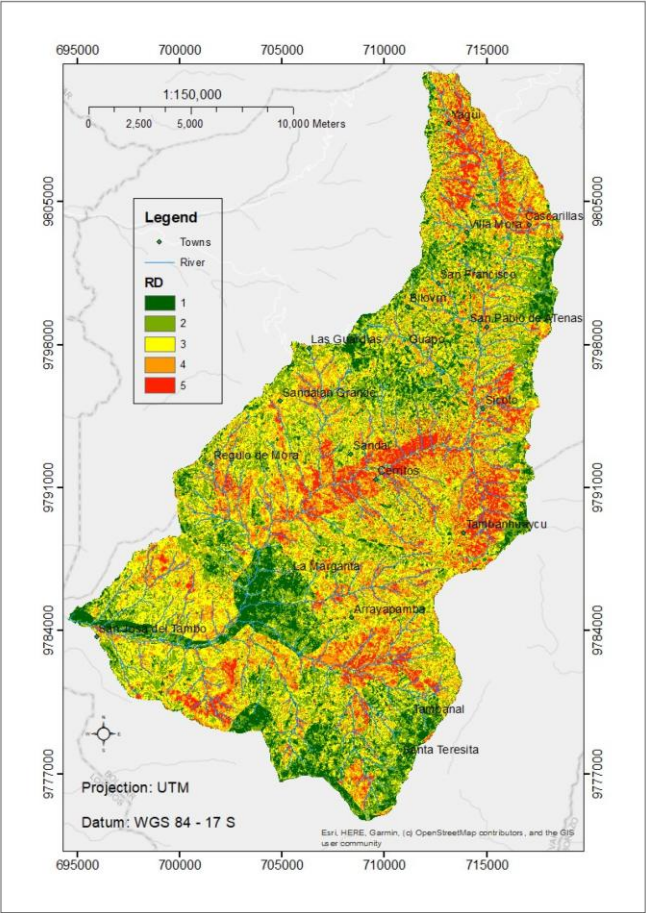
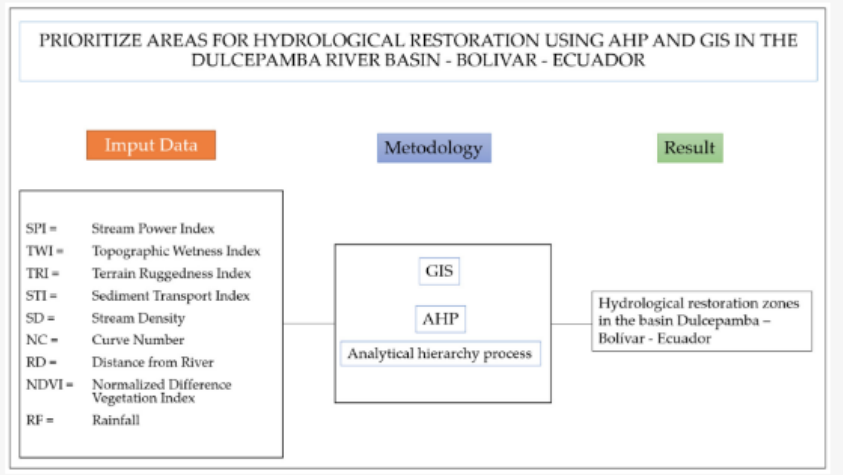
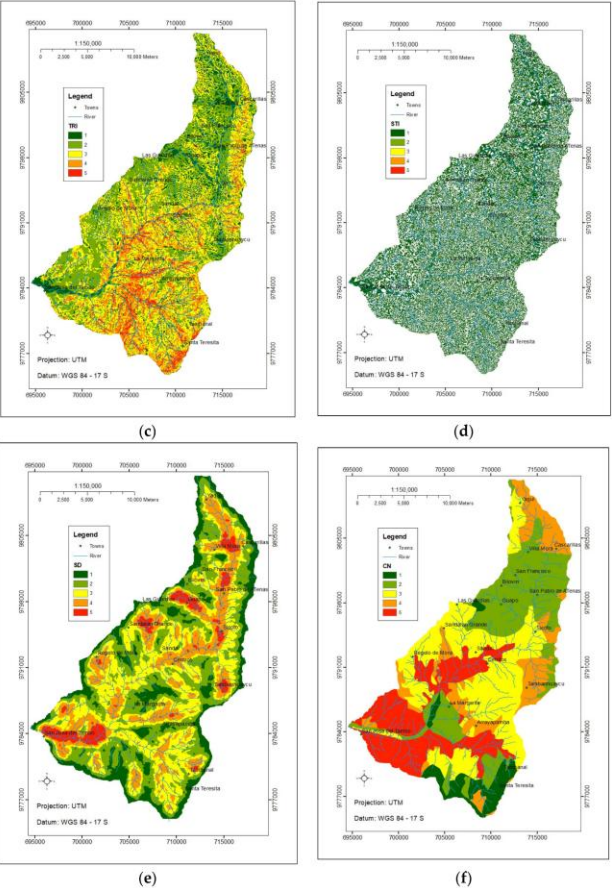
	NDVI	Slope	Stream Network	Roads	Criteria Weights
NDVI	0.6289	0.6002	0.6861	0.5000	0.6038
Slope	0.1258	0.1200	0.0858	0.2143	0.1365
Stream Network	0.1572	0.2401	0.1715	0.2143	0.1958
Roads	0.0898	0.0400	0.0572	0.0714	0.0646

$$\frac{0.6289+0.6002+0.6861+0.5000}{4} = 0.6038$$

$$\text{RISK} = 0.6038 \cdot \text{NDVI} + 0.1365 \cdot \text{SLOPE} + 0.1958 \cdot \text{STREAM_NETWORK} + 0.0646 \cdot \text{ROADS}$$

Multicriterion Analytical Hierarchy Process (AHP)

Weight	From	To	Category
1	122.93	236.24	Low HR
2	236.24	265.93	Low-medium HR
3	265.93	292.28	Average HR
4	292.28	322.17	High HR
5	322.17	461.64	Very high HR



Taller 5

Con un Script de R y Python ArcGIS:

Generar un mapa con clasificación de 5 categorías de la AHP usando los datos de NDVI y DTM, para el riesgo de deslizamiento del volcán Cotopaxi. Colocar los pesos aleatoriamente para las dos variables.



Gracias por su atención

César Iván Alvarez

cesarivanalvarezmendoza@gmail.com

<https://www.linkedin.com/in/cesar-ivan-alvarez-0847253a/>

